



- 百度网页搜索部 架构师
- 七年搜索引擎架构工作
 - 流式索引计算系统
 - 离线计算平台架构
 - 大规模在线服务治理
- 百度C++标准委员会委员
- 分布式系统 & 高可用架构

GIAC BEIJING Dec.12.16-17

thegiac.com









关键技术与实践难点











搜索引擎的挑战



unegiac.com



数万台服务器,数十万个服务,分布在多个IDC

服务变更多, 变更数据大

每天几十万次变更,每周10P量级的文件更新,千余人并行 开发上百个模块

检索流量大,稳定性要高

每秒数万次请求,满足99.995%的可用性,极短时间的故障都可能引发大量的拒绝

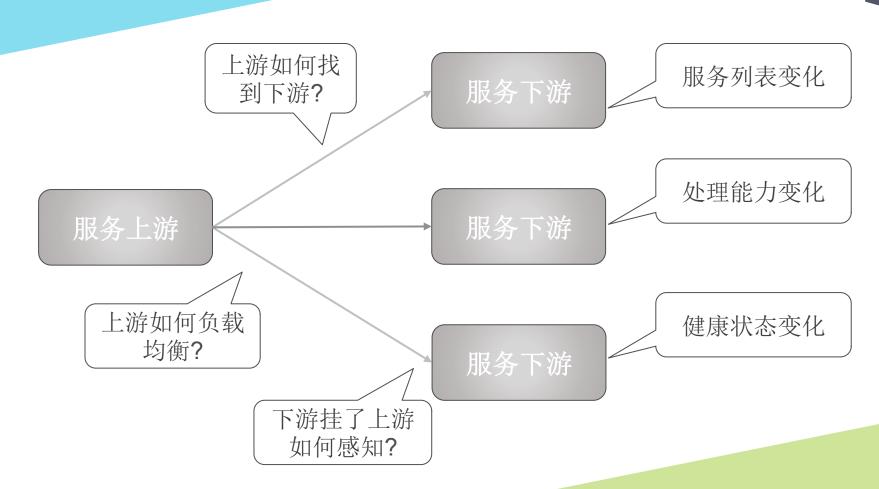


挑战



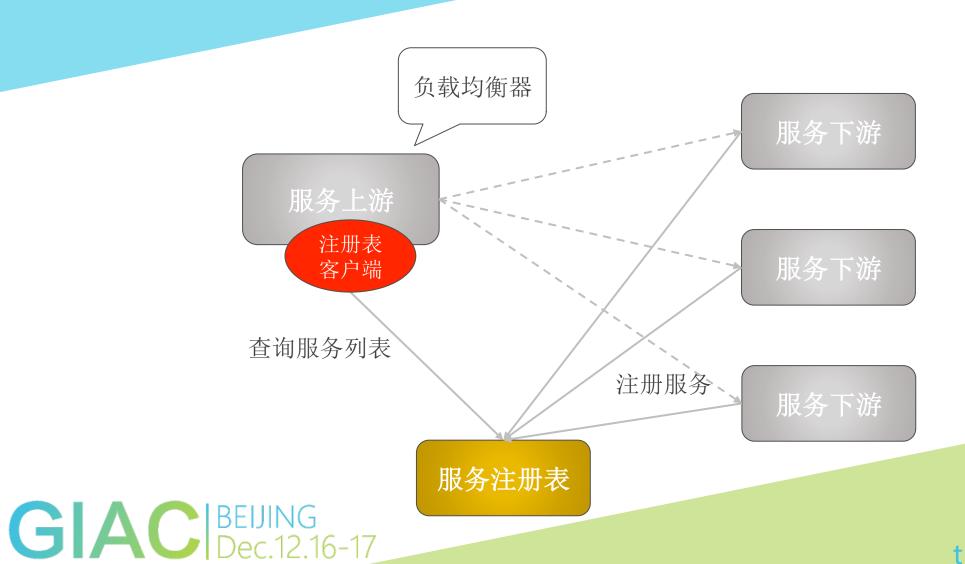


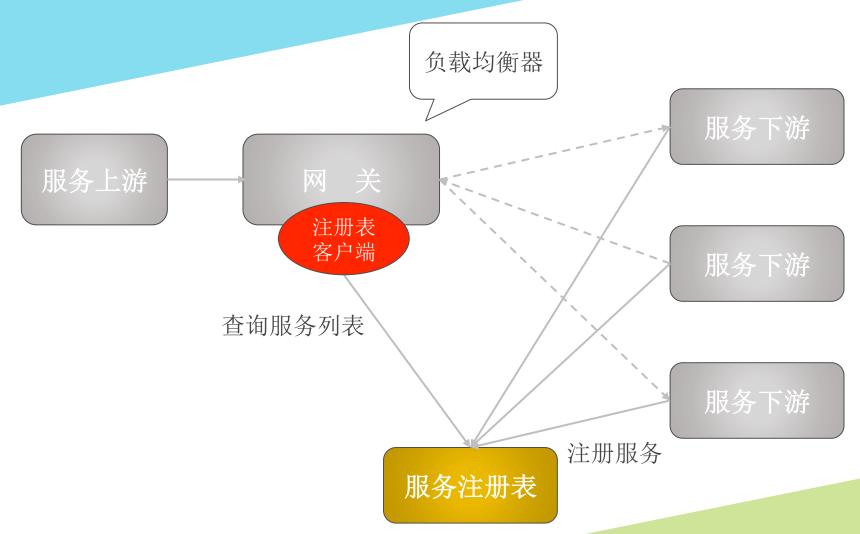
什么是服 务发现





客户端服 务发现







服务 注册表

- 分布式存储, 持久化服务地址和属性
- 服务名字全局唯一

- 支持增删改查
- 支持高并发高吞吐, 延迟要求不太高(几十ms)
- 读多写少





- 根据负载选择某个服务
- 故障服务的剔除和探活





关键技术与实践难点



可变服务

v.s. 不可变服务



Eden 架构蓝图

运行的服务

网页搜索

图片搜索

matrix

agent

度秘

信息流

服务升级

数据更新

Eden Job Engine

服务伸缩

实例迁移

matrix

II agent

测试支持

测试平台

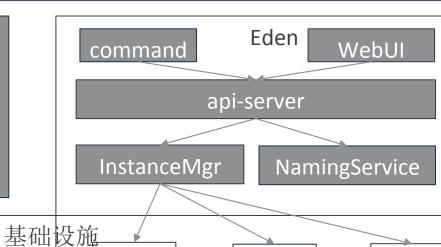
准入测试

日志服务

日志分析

日志收集

机器维修仲裁



matrix

II agent

监控系统

故障检测

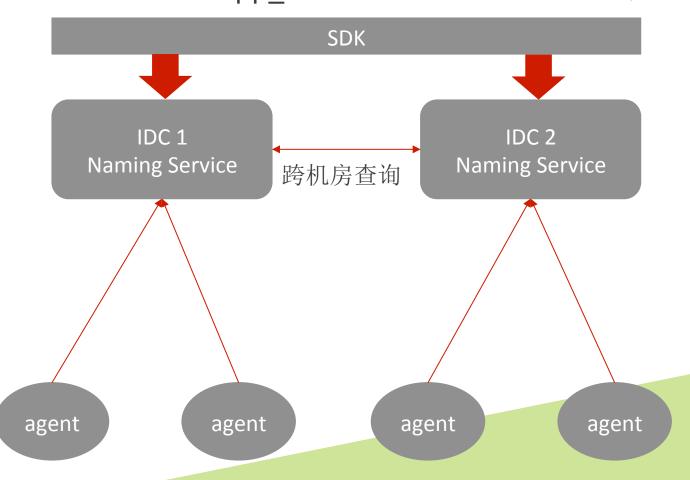
机器维修

GIACIBEIJING
Dec.12.16-17

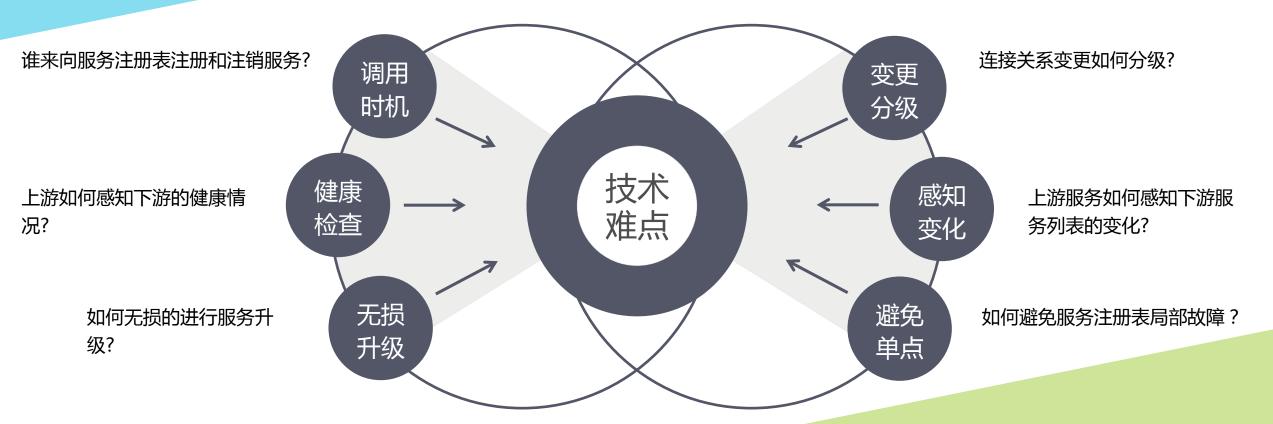
thegiac.com

```
},
"naming":{
    "default_ns_tag":{
    "ns_state":"NEW"
    },
"default_visible":true,
    "dependency":[
              "alias":"se_589",
              "app_id":"bs_se_589",
"attribute":{
                   "MIN_USABLE_RATIO":"90",
                  "SVC_GROUP": "all_bs, se, se_589"
              "version":"overlay_2016-11-23 17:19:371375344376"
              "alias": "se_590",
              "app_id":"bs_se_590",
              "attribute":{
                   "MIN_USABLE_RATIO":"90",
                  "SVC_GROUP": "all_bs, se, se_590"
              "version":"overlay_2016-11-23 17:19:37241337247"
              "alias":"se_591",
              "app_id":"bs_se_591",
"attribute":{
                  "MIN_USABLE_RATIO":"90",
"SVC_GROUP":"all_bs,se,se_591"
              "version":"overlay_2016-11-23 17:19:3773166471"
```

app_id必须全局唯一app_name.idc.zone

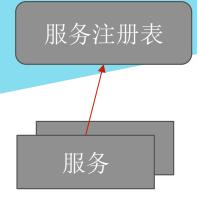


技术难点



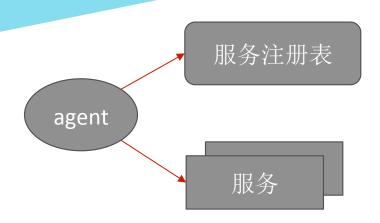


调用时机



服务自己

服务启停强依赖注册表 服务需要植入SDK 干扰运维可预期性 影响过载保护策略



第三方组件

添加删除时修改注册表不需要植入SDK 不需要植入SDK 弱依赖注册表 更容易运维效果监控 降低注册表负载



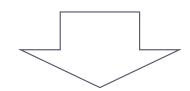
弱依赖注册表, 感知周期短, 准确性高



客户端和服务端建立心跳和探活机制

服务端健 康检查

服务自己做健康检查, 汇报给注册表



强依赖注册表, 未必准确, 感知周期长

客户端健 康检查



升级影响

升级就意味着同时重启的 服务数量比常态多

怎么办?

下游分组升级, 调度算法 支持跨组重试, 分组信息 持久化在服务注册表中

健康检测感知慢

健康检测虽然可以探测到 不可用的下游服务, 但是 健康检测存在周期性



失败概率大

上游服务访问下游服务失 败的概率增加

限制性重试

重试虽然可以一定程度上解决问题,但是重试副作用大,通常 重试次数被严格限制(3次)

GIAC BEIJING Dec.12.16-17

变更分级

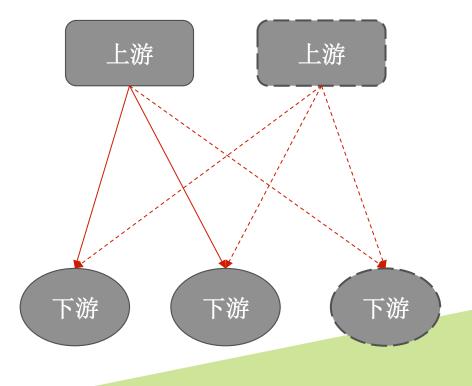


上游分级方式具有随机性, 出错情况损失偏大

基于分布式锁的个数, 控制上游变更的服务

给下游实例打tag, 标记是否被上游可见

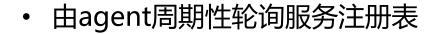
变更连接关系高危变更, 一旦错误, 损失很大







- zookeeper的通知机制不可靠
- 对注册表依赖过重,发生局部故障,影响服务可用性



- 引入版本节点, 只有版本变化时, 才获取全量数据
- 增强了运维的可预期性





避免单点



应用范围

最大 十万 分钟级

包含万级别的服务数量

包含十万级的服务实例数量

覆盖了百度搜索引擎规模最大的indexer服务

数千个实例扩缩容的索引分布调整, 分钟级完成连接变更

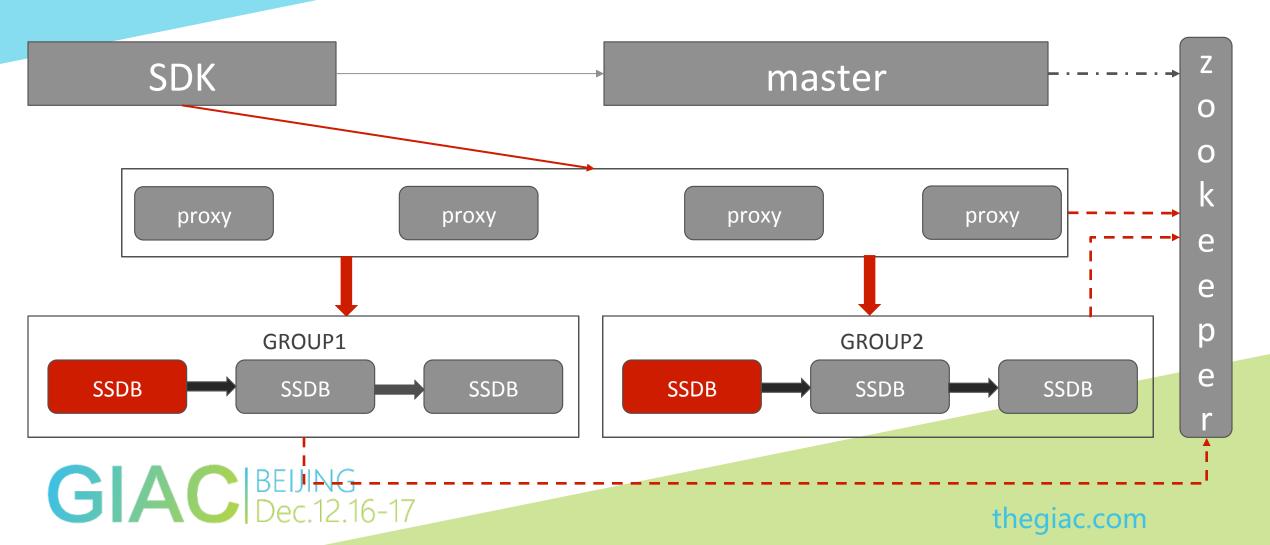






经典案例

高性能在线服务的分布式KV数据存储服务



相关对策

原有方案

ssdb向zk注册 ssdb通过zk选主 proxy watch zk master watch zk SDK watch zk 依赖zk session探活

暴露问题

网络抖动session超时 zk通知机制丢消息 zk故障服务整体不可用 平均1~2个月发生故障

迁移之后

利用心跳检测和探活

持久缓存服务列表

轮询获取服务列表

新旧方案对比







	consul	Eden
注册表存储	etcd	zookeeper
调用时机	服务自身/consul-template	agent
无损升级	可变服务变更需要额外机制	利用服务分组机制
健康检查	HTTP请求+机器环境	上下游心跳+检查脚本
变更分级	支持下游分级	上游分级+下游分级
变化感知	基于etcd的watch机制	轮询zookeeper
避免单点	依赖稍强	弱依赖



总结思考

总结

- 使用第三方组件注册和注销
- 上游探测下游服务健康状态
- 服务分组实现无损升级
- 连接关系变更一定要分级
- 使用轮询而不是通知

思考

• 引入类似k8s的endpoint机制

通过控制流量比例更好的实现分级

提升易用性,成为通用的中间件



技术架构未来







• 191895710





